

ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Super Resolution su immagini FFHQ

Confronto tra Total Variation e U-Net

Computational imaging 2025-26

Vincenzo Lombardi

Matricola: 0001235528

LM Scienze Informatiche – Curriculum C

Descrizione del progetto

Super Resolution come problema inverso

Obiettivo

Ricostruire immagini ad alta risoluzione da osservazioni degradate e rumorose.

Dataset: FFHQ 256×256
~4000 immagini

Task: Super
Resolution

Configurazioni richieste

(Modello di degradazione)

Downsampling $\times 2$ e $\times 4$

Rumore Gaussiano:

$\sigma \in \{0.005, 0.01\}$

Stessi input per tutti i modelli.

Metodi confrontati

Baseline: Bicubica

TV Regularization

U-Net

End-to-End method: U-Net

Metriche: PSNR e SSIM

Metodologia

Formulazione matematica

L'Equazione Fondamentale:

$$y = Ax + n$$

Anatomia dei termini:



HR Image



Degradation



Noise



LR Data



x (Incognito)

Segnale ad alta risoluzione (HR) che si desidera ricostruire.



A (Operatore)

Modella il processo fisico di acquisizione (blur, subsampling).



n (Rumore)

Incertezza additiva (gaussiana) introdotta dai sensori.



y (Osservato)

Dato a bassa risoluzione (LR) effettivamente acquisito.

Metodologia

Formulazione matematica (2)

La Sfida: Problemi Ill-Posed

- **Non-Unicità:**
 - *Infinite soluzioni HP compatibili con lo stesso input LA. L'operatore A "perde" informazioni irrecuperabili.*
- **Instabilità Numerica:**
 - *Il rumore viene amplificato esponenzialmente durante il tentativo di inversione diretta dell'operatore.*
- **Sensibilità al Rumore:**
 - *Piccole variazioni nei dati (y) portano a variazioni enormi e prive di senso fisico nella soluzione (x).*

La Soluzione: Regularizzazione

Per rendere il problema well-posed, introduciamo vincoli matematici.

- **Stabilizzazione:**
 - *Riduce la sensibilità al rumore n , evitando che l'inversione di A produca artefatti incontrollati*
- **Conoscenza a priori:**
 - *Introduciamo vincoli di regolarità (es. Tikhonov o Total Variation) basati sulla natura attesa del segnale HR.*

Metodologia: Total Variation

Metodo variazionale: Total Variation Regularization

✚_{x→} Formulazione: $\hat{x} = \operatorname{argmin} \{ \|Ax - y\|^2 + \lambda \operatorname{TV}(x) \}$

Formula TV isotropa discreta

✓ Vantaggi:

- preserva i bordi
- robusta al rumore gaussiano
- **Scelta di λ** : grid search su {0.02, su validation set

✗↓ Limiti:

- oversmoothing
- perdita texture fini
- effetto cartoon-like

- **Scelta di λ** : grid search su {0.02, 0.05, 0.08, 0.12, 0.20} con PSNR/SSIM

Implementazione:



denoise_tv_chambolle di scikit-image


TV applicato:



TV apli. su bicubic-upsampled image

Metodologia: U-Net

Metodo End-To-End: U-Net



Vantaggi:

- *apprende pattern complessi,*
- *recupera texture fini*

Limiti:

- *dipendente dai dati*
- *meno interpretabile*
- *costosa da addestrare*

Implementazione

Dataset e pipeline di degradazione

Dataset & Preprocessing:

FFHQ 256×256 ~4000 immagini

Split:

- 3200 train
- 400 val
- 400test


Normalizzazione [0,1]

Degradation model:

Downsampling ×2 / ×4,

AWGN $\sigma \in \{0.005, 0.01\}$,


bicubic upsampling to 256×256.



Configurazioni testate:

Scale	Noise
×2	0.005
×2	0.01
×4	0.005
×4	0.01

Pipeline:



Implementazione

Parametri di training della U-Net

Training setup:

Loss function: L1 Loss (MAE)

Optimizer: Adam

Learning rate: 10^{-3}

Batch size: 8, Epochs: 3




Struttura della rete:

Encoder con max pooling

Decoder con upsampling

Skip connections

Output RGB



La loss diminuisce rapidamente, ma il numero limitato di epoche vincola le prestazioni finali della rete.

Introduce the experiments

Setup sperimentale

Configurazioni & baseline

Le 4 combinazioni:

- $\times 2/\sigma=0.005$,
- $\times 2/\sigma=0.01$,
- $\times 4/\sigma=0.005$,
- $\times 4/\sigma=0.01$

Baseline:

Interpolazione Bicubica
(Senza regolarizzazione né
apprendimento)

Metrica: PSNR

(dB, più alto = meglio)
Valutazione pixel-wise

Metrica: SSIM


(0-1, più alto = meglio)
Valutazione percettiva

Stesso input per tutti i metodi → Confronto equo


Risultati quantitativi

Risultati numerici: PSNR e SSIM

Mean PSNR on test set



Mean SSIM on test set



Mean metrics on test set


Scenario: x2 $\sigma=.005$		Scenario: x2 $\sigma=.01$	
Method	Value	Method	Value
Bicubic	32.17 / .927	Bicubic	31.61 / .899
TV	32.37 / .933	TV	32.17 / .924
TV	32.23 / .928	TV	32.17 / .901
U-Net	32.23 / .928	U-Net	31.65 / .901

Scenario: x4 $\sigma=.005$		Scenario: x4 $\sigma=.01$	
Method	Value	Method	Value
Bicubic	26.26 / .800	Bicubic	26.11 / .774
TV	26.57 / .802	TV	26.56 / .801
TV	26.50 / .802	TV	26.56 / .801
U-Net	26.50 / .802	U-Net	26.35 / .778

Osservazione: TV è il migliore in tutte le configurazioni, vantaggio più netto con $\sigma=0.01$

Risultati quantitativi (Caso x2)


Confronto Visivo – Fattore x2



A $\times 2$ le differenze sono piccole, TV già più nitida della bicubica, U-Net comparabile

Risultati quantitativi (Caso x4)

Confronto Visivo – Fattore x4



La figura mostra che la differenza quantitativa è coerente con il comportamento visuale.

TV più robusta al rumore, U-Net conserva alcuni dettagli locali ma meno stabile
Bicubica chiaramente la peggiore visivamente

Notebook su GitHub:

Conclusioni

- TV è il metodo più performante in questo scenario: ottima regolarizzazione esplicita, robusta al rumore
- U-Net competitiva ma limitata dal training ridotto; con più epoche e dati probabilmente migliorerebbe
- Risultato interessante: i metodi variazionali classici rimangono estremamente competitivi rispetto al deep learning quando i dati e il compute sono limitati
- Metodi model-based e data-driven non sono alternativi ma complementari
- **Sviluppi futuri:**
 - Training più lungo con loss percettiva
 - Confronto con metodi ibridi (Plug-and-Play, Diffusion-based)
 - Estensione a deblurring/denoising su altri dataset

Riferimenti Bibliografici

- Rudin, Osher, Fatemi — Total Variation, Physica D, 1992
- Ronneberger, Fischer, Brox — U-Net, MICCAI, 2015
- Wang et al. — SSIM, IEEE TIP, 2004
- Dong et al. — Image SR with Deep CNN, IEEE TPAMI, 2016